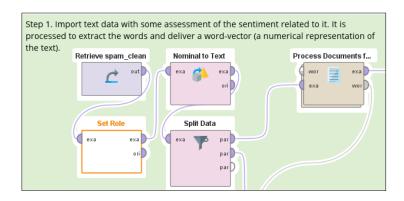
作業 6: 眾裡尋他千百度,那模型就在燈火欄珊處

現在我們就要開始來使用江湖中傳說的文字探勘絕學啦!

為了確保大家的學習品質,因此課程中一半的內容將做為作業的一部份;另一部份才是讓大家帶回去練習的作業唷!那我們就開始吧!!

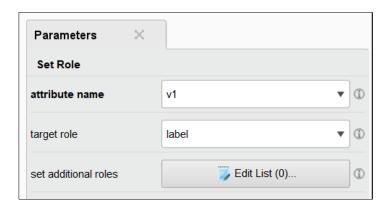
1. 請問啟 spam.xls 檔案! 並開始進行分析,開始前請針對需要的欄位進行必要 之前置處理. (10%)

〔前處理〕



- A. Retrieve spam_clean: 讀取 spam_clean.csv 資料

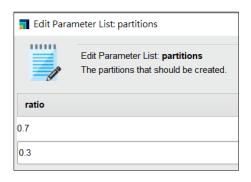
 Data 放置於資料夾內,檔名為 spam_clean.rmhdf5table
- B. Set Role:設定 v1 欄位為 label



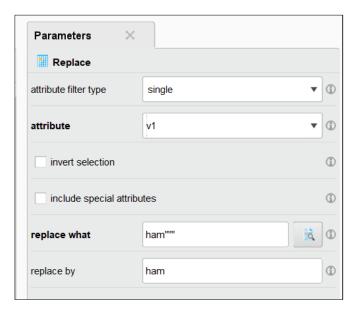
C. Nominal to Text: 資料轉為 text 型式



- ※ 由於讀入的資料其 v2 欄位屬性為 object, 因此要轉 text
- ※ 使用 Nominal to Text 將 v2 轉換為 text
- D. Split Data: 切分資料,訓練:驗證=70%:30%



E. (後續補充) Replace: 其中有兩筆資料讀成 ham""", 改為 ham。

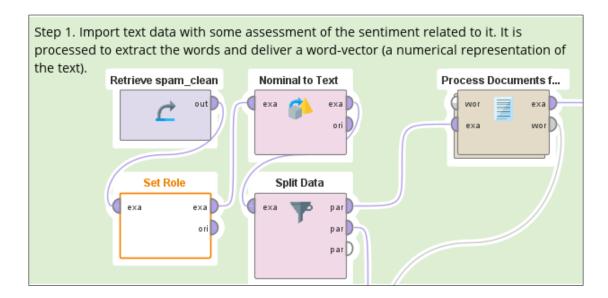


2. 接下來,我們要針對文字進行分析,因此有一些必要的處理程序,請說明一下您的步驟(10%),並請說明下列分析結果的意涵: TF-IDF (5%)

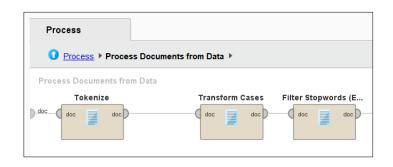
1. Step 1.

Import text data with some assessment of the sentiment related to it. It is processed to extract the words and deliver a word-vector (a numerical representation of the text).

- ▶ 資料前處理(見第一題描述)
- ▶ 導入文本數據,將文本拆解為 Token。



※ 使用 Process Documents from Data 來進行文字的處理



▶ 使用 Tokenize 進行斷詞斷句,亦可解釋為將文本拆分成單詞。

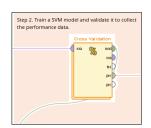
- ▶ 使用 Transform Case 進行大小寫轉換,這裡將大寫都轉換為小寫。
- ▶ 使用 Filter Stopwords(English)將停用詞刪除。
 - ※ (延伸解釋)什麼是停用詞 (Stop Words):

指一些頻繁出現、無具體含義或無助於文本分析的詞語,這些字詞對於文本並不具有明確的貢獻。在中文中常見的停用詞包括「的」、「和」、「在」、「是」、「了」、「及」、「或」等。

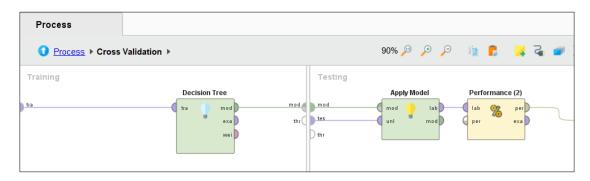
2. Step 2.

Train the model and validate it to collect the performance data.

訓練模型



←右圖, Cross Validation (交叉驗證)

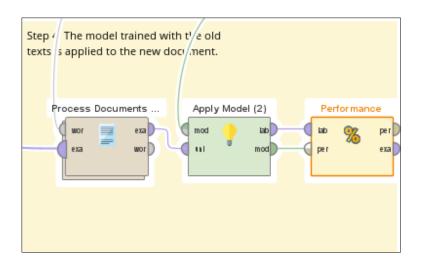


↑上圖,這裡以 Decision Tree 為例。

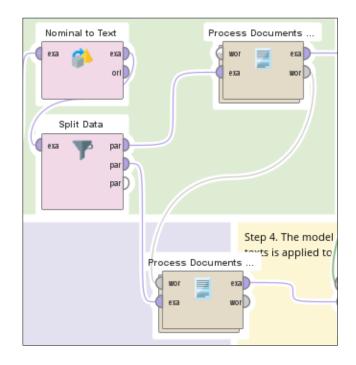
3. Step 3.

The model trained with the old texts is applied to the new document.

用訓練模型應用於 Testing Data。



- Testing Data 也要做斷詞斷句處理(Process Documents to Data),並且要給 word,讓它知道如何斷句。
- 使用 Apply Model 將訓練完的模型拿去與 Testing Data 進行測試
- 接上 Performance 來看模型的結果, 衡量正確率。

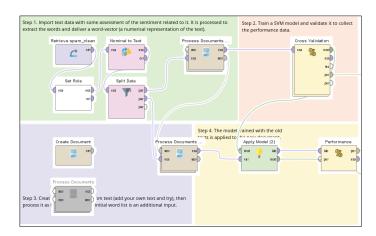


↑上圖·由於 Training Data 和 Testing Data 文字處理出來的字會不一

樣,這將會造成後面模型建置產生問題,所以要透過將訓練集的 word 接

出,連接至 Testing Data 的 word。

● 整體 Process 圖



 $tfidf_{i,j} = tf_{i,j} \times idf_i$

- ✓ TF-IDF
- TF-IDF 是一種用於資訊檢索與文字探勘的加權技術,是一種統計方法,目 的是想要過濾在檔案中常見的詞語,保留重要的詞語。
- TF-IDF 是由包含 TF(term frequency)及 IDF(inverse document frequency)兩個部分。

A. TF: 單詞出現在一份文件的頻率

例如:十萬 / 青年 / 十萬 / HR · 「十萬」出現了 2 次 · 總共有 4 個字 詞 · 因此 TF = 2/4 = 0.5

B. IDF: 單詞對於語料庫的重要程度

總共有 10 個文件,其中有5 個文件中有提及「十萬」這個字詞,因此 $IDF = log \ 10/5 = 0.3$

● 如果一個詞在一個特定檔案中具有高詞頻,在所有的檔案集合中具有低檔 案頻率,則會有高的 TF-IDF 權重。 3. 接下來,我們要開發製做一個垃圾郵件過濾器,請找出您能找出<u>正確率最高</u>的 分類機制,並略加說明(15%)

*註:因為有正確率評估的關係,請記得要使用訓練/測試集,又或是 Cross-

Validation

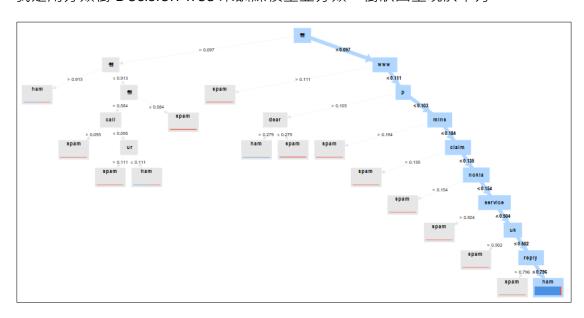
答覆:

● 以 V1 欄位作為 label, spam 為垃圾訊息、ham 為正常訊息。

我做出來的結果: Accuracy Ratio 為 94.53%

| accuracy: 94.53% | | | | |
|------------------|-----------|----------|-----------------|--|
| | true spam | true ham | class precision | |
| pred. spam | 135 | 8 | 94.41% | |
| pred. ham | 62 | 1075 | 94.55% | |
| class recall | 68.53% | 99.26% | | |

我是用分類樹 Decision Tree 來訓練模型並分類,樹狀圖呈現於下方。



〈略加說明〉

首先以「憯」作為關鍵字·若這個詞「憯」在這句話中的重要性(Ex. TF-IDF)

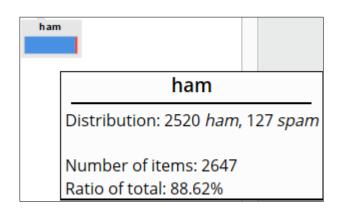
比重占超過 0.097, 則有可能是垃圾信件。



檢視全部資料,有包含「僭」這個詞的語句共 257 筆,僅 4 筆為 ham 正常訊息(4/257=1.56%),其餘 253 筆為 spam 垃圾訊息

(253/257=98.44%)。因此若有一筆新資料,當中包含「僭」這個詞,則歸類為垃圾訊息的機率很高。

其它重要的關鍵字包括:憯 ≤ 0.097 、www ≤ 0.111 、 $p \leq 0.103$ 、mins \leq 0.184、claim ≤ 0.135 、nokia ≤ 0.154 、service ≤ 0.504 、uk ≤ 0.502 、reply \leq 0.796 · 若通過了以上檢測,才很有可能是 ham 正常訊息。



※ 已將 process 流程儲存為 111C71008-1.rmp

4. 接下來,承上述步驟,請使用 Womens Clothing E-Commerce Reviews.csv 檔案進行分析,在這邊我們希望您可以借由分析評論來預測評分或是您認為值得分析的議題. 另外也請您自行思考一下還有什麼分析可以進行並說明結果唷 (60%)。

答覆:

[想法]

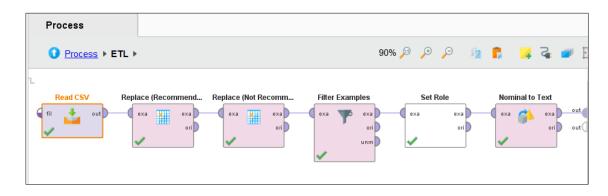
借由分析評論(Review Text 欄位)來判斷顧客的意見是正面或負面 (Recommended 推薦此項產品→正面; Not Recommended 不推薦此項產品→負面)

※ Recommended IND 欄位的意思:

表示客戶是否推薦此項產品,1為推薦,0為不推薦。

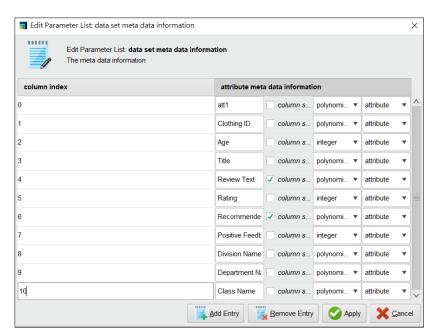
(Binary variable stating where the customer recommends the product where 1 is recommended, 0 is not recommended.)

[簡略提一下前處理,方便閱讀]



※ 模仿 spam_clean.csv 資料格式

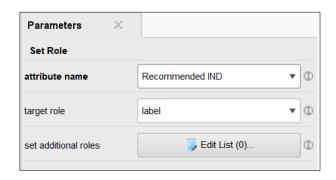
● 在讀取時,僅讀取 Review Text 及 Recommended IND 欄位



- 將 Recommended IND 欄位中的 1 取代為 Recommended; 0 取代為 Not
 Recommended。
- 刪 Review Text 為 Missing 及 Recommended IND 不包含
 Recommended。



● 設定 Recommended IND 為 Label



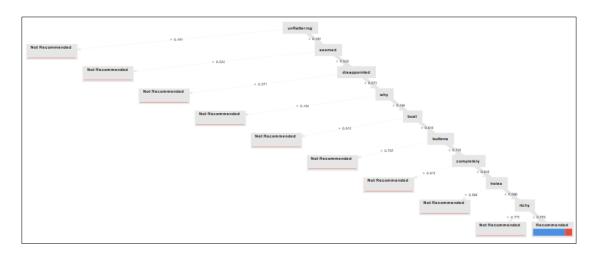
● Nominal to Text: 資料轉為 text 型式

[說明分析結果]

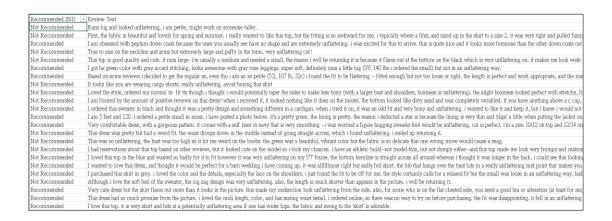
● 我做出來的結果: Accuracy Ratio 為 81.83%

| accuracy: 81.83% | | | | |
|-----------------------|------------------|----------------------|-----------------|--|
| | true Recommended | true Not Recommended | class precision | |
| pred. Recommended | 4973 | 1099 | 81.90% | |
| pred. Not Recommended | 8 | 12 | 60.00% | |
| class recall | 99.84% | 1.08% | | |

● 我是用分類樹 Decision Tree 來訓練模型並分類,樹狀圖呈現於下方。



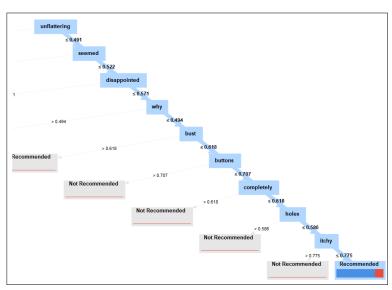
● 首先以「unflattering」作為關鍵字·若這個詞「unflattering」在這句話中的重要性(Ex. TF-IDF)比重占超過 0.491·則有可能是負面評論。



檢視全部資料,有包含「unflattering」這個詞的語句共 299 筆,其中 209 筆為負面評論(209/299 約為 70%),剩餘 90 筆為正面評論

(90/299=30%)。因此若有一筆新的顧客評論,當中包含 「unflattering」這個詞,則歸類為負面評論的機率較高。

其它重要的關鍵字包括:unflattering ≤ $0.491 \times \text{seemed} \le 0.522 \times \text{disappointed} \le 0.571 \times \text{why} \le 0.494 \times \text{bust} \le 0.618 \times \text{buttons} \le 0.707 \times \text{completely} \le 0.618 \times \text{holes} \le 0.586 \times \text{itchy} \le 0.775 \times \text{若通過了以上檢}$ 測,才很有可能是正面評論。





- ✓ 另外可以再深入分析,探討包含年齡、產品部門與正面評論的彼此關係。
 例如哪一年齡階層給予最多正面評論,或是哪一個產品部門獲得最多的正面評論。
- ※ 已將 process 流程儲存為 111C71008-2.rmp